

RELAZIONE LINGUISTICA COMPUTAZIONALE II

Martina Perodi 634097

Introduzione

Il progetto affronta il compito di *authorship attribution*, ovvero l'identificazione automatica dell'autore di un testo all'interno di un insieme di candidati predefiniti. L'obiettivo del lavoro è stato sviluppare e confrontare diversi sistemi di classificazione testuale.

Ciascun metodo è stato addestrato e valutato su dati provenienti da tre autori inglesi (Dickens, Austen e Woolf), con lo scopo di confrontarne l'accuratezza, la capacità di generalizzazione e la robustezza. La relazione descrive quindi le fasi principali del lavoro.

Testi utilizzati

Per la realizzazione del progetto sono stati scaricati dei testi dal sito *Progetto Gutenberg*.

Per avere più scelta, sono stati scelti testi in lingua inglese. In particolare sono stati selezionati i tre autori Dickens, Austen e Woolf. Di ciascuno si sono poi scaricati abbastanza scritti per garantire un corpus che potesse rispettare le specifiche del progetto. Di seguito si riportano i testi usati con qualche informazione che li caratterizza.

- *A Christmas Carol*, Charles Dickens: è una novella o racconto di fantasmi pubblicata a Londra nel 1843.
- *David Copperfield*, Charles Dickens: è un romanzo in parte autobiografico pubblicato per la prima volta su una rivista tra il 1819 e il 1850.
- *Oliver Twist*, Charles Dickens: è un romanzo pubblicato a puntate ma diventato libro già nel 1838 che viene definito romanzo sociale, che rovescia il romanzo di formazione e fa largo uso di un dissacrante umorismo nero.

- *Emma*, Jane Austen: è un romanzo del 1815 che ha per tema il fraintendimento in amore.
 - *Mansfield Park*, Jane Austen: è un romanzo del 1814 che esplora temi come le classi sociali, la moralità e l'educazione.
 - *Pride and Prejudice*, Jane Austen: è un romanzo che viene pubblicato nel 1813 e ha come temi il matrimonio e il ruolo femminile nella società dell'epoca.
 - *The Common Reader*, Virginia Woolf: è una raccolta di saggi uscita tra il 1925 e il 1932 che esplora il ruolo e il piacere della lettura.
 - *Monday or Tuesday*, Virginia Woolf: sono dei racconti usciti nel 1921.
 - *Mrs. Dalloway*, Virginia Woolf: è un romanzo pubblicato nel 1925 che racconta la giornata della protagonista.
 - *Night and Day*, Virginia Woolf: è un romanzo uscito per la prima volta nel 1919 che racconta la vita quotidiana di due amiche e i loro rapporti tra amore, matrimonio, felicità e successo.
 - *The Voyage Out*, Virginia Woolf: romanzo del 1915 che racconta il viaggio di formazione della protagonista che si imbarca su una nave.
-

Normalizzazione

I testi scelti sono stati suddivisi poi in paragrafi. Per fare ciò, prima si è passati per una fase di normalizzazione.

I paragrafi sono stati identificati nel testo da '\n\n', quindi andavano gestiti tutti gli altri casi. In particolare, sono stati normalizzati i rientri a capo all'interno del testo (segnalati da una '\n' che grazie a una regex è stata sostituita da uno spazio bianco) e alcuni punti particolari dove erano presenti più '\n' (quindi dove c'erano '\n\n\n' o più) che sono stati riportati al canonico '\n\n'.

A questo punto si sono ottenuti i testi normalizzati da cui si possono estrarre i paragrafi.

Sono stati analizzati i paragrafi di tutti i testi e sono stati selezionati per essere usati nel dataset solo i paragrafi che contenevano tra i 50 e i 100 tokens.

Il dizionario annidato risultato di questa operazione è stato strutturato per tenere traccia anche dell'autore e del libro da cui i paragrafi sono estratti.

Dataset

Il dataset è stato suddiviso in tre sottoinsiemi: training set, test set e validation set. Il training set è formato da 1000 paragrafi per ciascun autore, mentre test set e validation set sono composti da 100 paragrafi per ciascuno. Per ogni paragrafo è stato creato un file .txt.

I testi usati nel test set e nel validation set non sono stati usati per il training set per garantire una corretta valutazione delle capacità dei modelli.

In particolare, dal training set sono stati tolti:

- *David Copperfield*, Charles Dickens
- *Pride and Prejudice*, Jane Austen
- *Mrs. Dalloway*, Virginia Woolf
- *The Common Reader*, Virginia Woolf
- *Monday or Tuesday*, Virginia Woolf

Questi testi quindi sono stati usati per il validation set e per il test set.

Classificatore basato su Support Vector Machine (SVM) lineari e informazioni linguistiche non lessicali

Il primo classificatore è basato sulle informazioni linguistiche non lineari estratte da Profiling UD. Le feature estratte sono 124 e sono state successivamente normalizzate per renderle confrontabili tra loro.

A questo punto è stato usato un SVM lineare per creare e addestrare il classificatore.

Per la valutazione del modello è stata eseguita una procedura di cross-validation a 5 fold sul training set. Da queste iterazioni è stata calcolata una overall accuracy di 0.68. È stato poi fatto un confronto con DummyClassifier (baseline “classe più frequente”), con accuracy 0.33.

Il modello è stato valutato sul test set e sul validation set ottenendo rispettivamente delle accuracy pari a 0.48 e 0.47. Sono state prodotte le corrispondenti matrici di confusione (Fig1).





Fig. 1 Sulla sinistra la matrice del test e a destra quella del validation

Dalle matrici si può notare che il modello riconosce meglio i testi di Austen, mentre per gli altri due autori, il modello tende ad attribuire erroneamente i testi a Austen. È stato poi fornito un elenco (Fig. 2) delle 20 features più rilevanti ai fini della classificazione per ogni autore.






Fig. 2 Le features per i testi di (dall'alto) Austen, Dickens, Woolf

Classificatore basato su SVM lineari e n-grammi

Il secondo classificatore si basa su un SVM e su una rappresentazione del testo fondata su n-grammi di caratteri, parole e part-of-speech.

Sono state sperimentate diverse configurazioni per la rappresentazione del testo, variando la lunghezza degli n-grammi considerati e il tipo di informazione:

- 1-grammi e 2-grammi di parole e di caratteri
- 1-grammi e 2-grammi di parole e di POS
- 1-grammi e 2-grammi di POS e di caratteri
- 1-grammi e 2-grammi di parole e di lemmi

La configurazione migliore è risultata essere quella che considerava 1-grammi e 2-grammi di parole e di lemmi, con un'accuracy dello 0.70.

Quindi si è proceduto con la valutazione sul test set di questa configurazione ed è stata prodotta la matrice di confusione in Fig.3.




Fig 3. Matrice di confusione sul test set della configurazione 1-grammi e 2-grammi di parole e di lemmi

Classificatore basato su SVM lineari e word embedding

Il terzo classificatore si basa su una rappresentazione con word embedding e un SVM lineare come modello di classificazione.

Sono state testati diversi modi di rappresentare il testo, aggregando gli embegging in modo diverso e anche prendendo in considerazione diverse categorie grammaticali:

- Metodo che calcola la media di tutti i word embeddings
- Metodo che calcola la media dei word embeddings solo di aggettivi,
- Metodo che calcola la media separatamente dei word embedding di aggettivi, nomi e verbi, e concatena i 3 vettori ottenuti.

Il primo metodo, con un'accuracy dello 0.77, è risultato essere quello più performante e quindi è stato valutato sul test set.

Dalla valutazione notiamo un'accuracy dello 0.67 e una matrice di confusione (Fig. 4) che riconosce abbastanza bene tutti e tre gli autori.




Fig. 4 Matrice di confusione sul test set del metodo che calcola la media di tutti gli embedding

Fine-tuning di un modello di linguaggio neurale (Neural Language Model)

Per il quarto task è stato utilizzato il modello Bert per l'inglese 'bert-base-uncased' che è stato fine-tunato per sei epoche durante le quali sono state calcolate le sue prestazioni.




Fig. 5 Curve di loss relative a training e validation set

Si sono ottenute le curve di loss relative a training e validation set (Fig. 5). Si può notare come la curva del training si abbassi fino allo zero, mentre quella di validation rimane alta, segno che il modello tende all'overfitting.

I risultati ad ogni epoca sono riportati nella seguente tabella (Fig. 6).

Epoch	Training Loss	Validation Loss	F1
1	0.301800	0.734265	0.795049
2	0.031200	1.316533	0.752651
3	0.003800	1.107043	0.799610
4	0.000400	1.175619	0.802832
5	0.000200	1.189114	0.802832
6	0.000200	1.196141	0.805903

Fig. 6 Risultati di ogni epoca

A questo punto è stato valutato il modello sul test set, ottenendo una accuracy dello 0.77 e la seguente matrice di confusione (Fig. 7), dove notiamo che il modello riconosce molto bene i testi di Austen, mentre, seppur riconoscendo correttamente la maggior parte dei testi di Dickens e di Woolf, ogni tanto li inverte tra loro.




Fig. 7 Matrice di confusione sul test set

Conclusioni

Il progetto ha permesso di confrontare diversi approcci al compito di authorship attribution, mettendo in evidenza come la scelta della rappresentazione testuale e del modello di classificazione incida in maniera determinante sulle prestazioni.

Il primo classificatore, basato su SVM e features linguistiche non lessicali, ha superato la baseline ma ha mostrato un'accuratezza limitata, con una forte tendenza ad attribuire i testi ad Austen. Questo indica che il modello riesce a cogliere alcuni tratti stilistici generali, ma non sufficienti a distinguere con chiarezza tra autori dallo stile più complesso o variabile come Dickens e Woolf. Ne consegue che le sole features linguistiche non lessicali non sono in grado di catturare appieno la ricchezza stilistica richiesta dal task.

Il secondo approccio, basato sugli n-grammi, ha offerto un chiaro miglioramento, raggiungendo un'accuracy pari a 0.70 nella configurazione con unigrammi e bigrammi di parole e lemmi.

L'introduzione dei word embeddings ha consentito un ulteriore salto di qualità: la rappresentazione ottenuta tramite la media degli embedding si è rivelata la più efficace, con un'accuracy di 0.77 in validazione e 0.67 sul test set. Questo approccio ha garantito un riconoscimento più equilibrato dei tre autori, mostrando una migliore capacità di generalizzazione rispetto ai modelli precedenti.

Il fine-tuning di BERT ha infine raggiunto le migliori prestazioni complessive, con un'accuracy dello 0.77 sul test set. Le curve di loss hanno però evidenziato segnali di overfitting, suggerendo la necessità di introdurre strategie di regolarizzazione o di ampliare la varietà dei dati per consolidare la capacità di generalizzazione del modello.

In tutti i modelli emerge come i testi di Austen siano più facilmente riconoscibili, mentre quelli di Dickens e Woolf risultino più difficili da distinguere e vengano spesso confusi tra loro. Questo riflette le differenze stilistiche tra gli autori e conferma la maggiore peculiarità dello stile di Austen rispetto agli altri due.